

Analisis Perbandingan Performa Arsitektur CNN Klasik pada CIFAR-10 dan Transfer Learning pada *Cats vs Dogs*

Abstrak

Penelitian ini bertujuan untuk membandingkan dua pendekatan Deep Learning yang diamanatkan dalam kurikulum, yaitu Convolutional Neural Network (CNN) *from scratch* menggunakan dataset CIFAR-10 dan teknik *Transfer Learning* menggunakan dataset Cats vs Dogs. Kedua eksperimen menerapkan pembagian data standar 70% Training, 15% Validation, dan 15% Testing. Untuk menekan risiko *overfitting* pada data citra alam, teknik augmentasi data berupa pembalikan dan rotasi gambar acak turut diimplementasikan. Hasil pengujian akhir menunjukkan bahwa model Transfer Learning menghasilkan akurasi sebesar **88.57%** dalam waktu **55.89 detik**, sementara CNN *from scratch* pada CIFAR-10 menghasilkan akurasi sebesar **67.86%** dalam waktu **331.19 detik**.

Kata Kunci : *Deep Learning, CNN From Scratch, Transfer Learning, MobileNetV2, CIFAR-10, Cats vs Dogs.*

Pendahuluan

Studi komparatif antara melatih jaringan saraf dari awal (*from scratch*) dan memanfaatkan jaringan yang telah dilatih sebelumnya (*pretrained model*) merupakan fondasi penting dalam memahami efisiensi model Deep Learning. Tantangan utama dari pembuatan arsitektur mandiri adalah penentuan parameter yang optimal serta tingginya risiko *overfitting* apabila jumlah data atau kapasitas komputasi tidak memadai.

Sesuai dengan instruksi tugas, makalah ini membedah dua skenario uji. Eksperimen pertama mengevaluasi performa arsitektur CNN dasar dalam mengenali 10 kelas objek umum pada dataset CIFAR-10. Eksperimen kedua menguji keandalan arsitektur MobileNetV2 melalui strategi *Feature Extraction* untuk melakukan klasifikasi biner pada dataset Cats vs Dogs.

Metodologi Penelitian

A. Deskripsi Dataset & Pra-pemrosesan Data

Dataset CIFAR-10 (Eksperimen 1): Terdiri dari gambar berukuran 32×32 piksel yang mencakup 10 kelas objek (pesawat, mobil, burung, kucing, rusa, anjing, katak, kuda, kapal, dan truk). Data dinormalisasi dengan membagi nilai piksel dengan 255.0 agar berada pada rentang 0-1.

Dataset Cats vs Dogs (Eksperimen 2): Menggunakan koleksi citra biner kucing dan anjing dengan resolusi yang diseragamkan menjadi 128×128 piksel.

Kedua dataset dibagi secara konsisten dengan proporsi **70% data training**, **15% data validation**, dan **15% data testing**.

B. Pengayaan Dataset (Data Augmentation)

Khusus pada eksperimen Transfer Learning Cats vs Dogs, sebuah *layer Sequential* augmentasi disisipkan untuk memanipulasi gambar secara acak pada setiap epoch. Teknik yang digunakan meliputi *Random Flip* horizontal untuk mensimulasikan arah hadap visual, serta

Random Rotation dan *Random Zoom* sebesar 10% untuk memperkaya variasi geometri objek visual.

C. Arsitektur Model Eksperimen

CNN from Scratch (CIFAR-10):

Dirancang menggunakan 3 *Convolutional layers* (fungsi aktivasi ReLU) dikombinasikan dengan *Max Pooling 2D* untuk reduksi dimensi fitur. Fitur kemudian diratakan menggunakan *Flatten*, dihubungkan ke *layer* yang berisi 64 neuron dengan pengaman *Dropout* 0.3, dan diakhiri *Output layer Dense* beraktivasi Softmax dengan 10 unit kelas.


Transfer Learning (Cats vs Dogs):

Menggunakan arsitektur *MobileNetV2* yang dibekukan (*weights='imagenet'*, *trainable=False*) sebagai *Feature Extractor* otomatis. Lapisan klasifikasi baru dibentuk menggunakan *Global Average Pooling2 D*, diikuti *Dense layer* 64 neuron, *Dropout* 0.3, dan *Dense output layer* beraktivasi Sigmoid untuk menghasilkan klasifikasi biner.

Hasil Eksperimen dan Perbandingan Model

A. Visualisasi Performa

Setelah proses training selesai dieksekusi (10 epoch untuk CNN Scratch dan 5 epoch untuk Transfer Learning), grafik perbandingan konvergensi akurasi dan loss tercetak sebagai berikut:



B. Perbandingan Komparatif Antar Aspek

Evaluasi objektif performa akhir pada data pengujian dirangkum dalam tabel standardisasi di bawah ini:

Tabel Perbandingan Karakteristik dan Hasil Eksperimen Model

Aspek Evaluasi	CIFAR-10	Cats vs Dogs
Akurasi Training	72.45%	92.82%
Akurasi Validation	68.27%	91.62%
Akurasi	67.86%	88.57%

Aspek Evaluasi	CIFAR-10	Cats vs Dogs
Testing		
Loss Training	0.7908	0.1799
Loss Validation	0.9043	0.1786
Waktu Training	331.19 detik	42.25 detik
Jumlah Parameter	Sedikit	Sangat Banyak
Risiko Overfitting	Sedang-Tinggi	Rendah
Kemudahan Implementasi	Sedang	Sangat Mudah
Kesesuaian Dataset	Cocok untuk citra dimensi kecil	Sangat cocok untuk citra beresolusi tinggi

Berikut adalah representasi detail *Confusion Matrix* hasil tebakan pada masing-masing eksperimen:

```
[CONFUSION MATRIX - CNN SCRATCH (CIFAR-10)]
[[598 10 126 43 35 26 10 22 78 52]
 [ 17 692 11 23 7 13 19 7 32 179]
 [ 36 3 529 77 85 142 93 21 4 10]
 [ 6 2 49 464 42 321 60 30 4 22]
 [ 11 1 67 86 592 92 83 57 7 4]
 [ 4 0 26 126 27 751 24 32 2 8]
 [ 2 1 36 83 12 48 807 3 3 5]
 [ 4 0 29 38 68 126 4 714 1 16]
 [ 39 15 23 40 11 19 10 8 792 43]
 [ 14 32 10 31 3 15 13 13 22 847]]

[CONFUSION MATRIX - TRANSFER LEARNING (CATS VS DOGS)]
[[55 15]
 [ 1 69]]
```

Confusion Matrix

C. Contoh Hasil Prediksi Benar dan Salah

- Contoh Prediksi Benar



- Contoh Prediksi Salah



Analisis Mendalam

A. Analisis Karakteristik Dataset

Dataset CIFAR-10 yang ditangani CNN *from scratch* berjumlah cukup masif (50.000 data latih), namun resolusinya

yang terlampau kecil 32×32 membatasi detail fitur visual. Untuk Cats vs Dogs, ukuran sampel medium sudah sangat memadai bagi Transfer Learning.

Variasi citra kedua dataset sudah sangat baik. Tidak ditemukan isu ketidakseimbangan data karena distribusi sampel antar kelas terbagi secara merata (50:50).

Pada Cats vs Dogs, gambar memiliki tingkat kompleksitas latar belakang (*outdoor* / *indoor*) serta noise pencahayaan yang tinggi. Hal ini berimbas pada performa model; di mana kualitas background yang acak akan mengacaukan ekstraksi fitur jika dilatih dari nol, tetapi sukses ditangani oleh Transfer Learning berkat kematangan bobot parameter ImageNet.

B. Analisis Performa Model

Model *Transfer Learning* mencatatkan performa terbaik dengan nilai akurasi uji tertinggi. Akurasi tinggi tidak serta-merta mutlak menunjukkan kualitas model terbaik jika jarak akurasi training dan validasi terlampau jauh (*overfitting*).

Indikasi *overfitting* terkendali dengan baik pada kedua eksperimen berkat pemasangan *layer Dropout* dan pengayaan augmentasi data. Selama

proses training berlangsung, model Transfer Learning menunjukkan kestabilan konvergensi grafik yang jauh lebih mulus dibandingkan model *from scratch* sejak epoch pertama. Skenario ini membuktikan hubungan positif di mana keterbatasan data latih fisis dapat dikompensasi secara optimal lewat transfer pengetahuan arsitektur pretrained.

C. Analisis Pemilihan Pendekatan Rekomendasi

Berdasarkan bukti empiris, *CNN from scratch* sebaiknya dipilih ketika kita memiliki jumlah dataset internal berskala raksasa (ratusan ribu data), karakteristik visual objeknya sangat langka/terisolasi (tidak ada kemiripan dengan ImageNet), serta didukung oleh infrastruktur komputasi GPU yang tinggi dan waktu pengembangan yang panjang.

Sebaliknya, *Transfer Learning* wajib menjadi pilihan utama jika kita dihadapkan pada keterbatasan jumlah sampel gambar, kemiripan objek tinggi dengan dataset ImageNet, urgensi kebutuhan akurasi tinggi yang instan, efisiensi waktu komputasi, serta tuntutan kemudahan dalam proses *deployment* sistem di lingkungan industri nyata.

Studi Kasus Pengambilan Keputusan

Skenario 1

Memilih pendekatan *Transfer Learning*. Jumlah data 300 lembar citra medis terlampaui mustahil untuk melatih CNN dari nol tanpa memicu *overfitting* destruktif. Arsitektur pretrained (misalnya DenseNet) yang sudah terlatih mengekstrak bentuk-bentuk geometri dasar dari ImageNet akan jauh lebih adaptif menerima data medis terbatas.

Skenario 2

Pendekatan *CNN from scratch* sangat relevan. Dengan modal dataset masif (1 juta gambar) dan karakteristik visual internal yang sangat berbeda dari ImageNet, model dari nol akan jauh lebih objektif dalam mempelajari fitur-fitur spesifik produk tanpa terdistorsi oleh bias pemahaman ImageNet sebelumnya.

Skenario 3

Pendekatan yang paling rasional adalah *Transfer Learning*. Keterbatasan waktu pengerjaan (2 hari) dikombinasikan

dengan minimnya data (500 gambar) menuntut efisiensi koding. Transfer Learning menawarkan kecepatan komputasi instan dengan jaminan akurasi tinggi yang siap dipresentasikan.

Skenario 4

(Dataset besar, GPU memadai, domain sangat spesifik): Transfer Learning tetap diperlukan, namun menggunakan strategi Fine-Tuning.

Dibanding membangun arsitektur tebakan dari nol, membuka sebagian *layer* teratas pretrained model untuk dilatih kembali bersama dataset besar kita jauh lebih efisien. Model tidak perlu membuang daya komputasi untuk belajar mendeteksi tepi garis gambar dari nol lagi.

Kesimpulan & Refleksi Pribadi

A. Kesimpulan

Eksperimen komparatif Deep Learning ini berhasil membuktikan bahwa keandalan model tidak hanya bergantung pada kedalaman arsitektur, melainkan dipengaruhi secara krusial oleh aspek sebelum pemrosesan data, kesesuaian domain pengetahuan

pretrained model, dan strategi penekanan risiko bias.

B. Refleksi Pribadi

1. Tantangan terbesar dalam tugas ini adalah mematangkan konfigurasi dataset masif secara lokal dan menyinkronkan jalur folder komputer ke dalam API visualisasi TensorFlow tanpa memicu error memori.

2. Bagian tersulit adalah mendesain arsitektur CNN from scratch, karena penentuan parameter convolutional filter dan learning rate murni didasarkan pada metode trial-and-error yang menguras waktu komputasi.

3. Perbedaan paling fundamental yang saya rasakan adalah efisiensi energi komputasi, di mana pretrained model mampu langsung melompat ke akurasi tinggi pada epoch awal, sementara model scratch membutuhkan proses belajar yang sangat lamban.

4. Pada implementasi industri kasus nyata, saya akan memprioritaskan Transfer Learning demi menekan biaya operasional komputasi server dan mempercepat fase deployment produk.

5. Hal baru terpenting yang saya pahami adalah bahwa pengambilan keputusan

arsitektur Deep Learning harus didasarkan pada kompromi matematis antara ketersediaan data fisis, batasan hardware GPU, dan efisiensi waktu.